

Animal Species Classifier

Цель. Обучить модель классификации животных по фотографиям с камер-ловушек из сегмента СНГ.

Проблема

Открытых датасетов с камер-ловушек для СНГ практически нет. Единственный найденный — RedForest (Чернобыльская зона): ~4 тыс. фотографий, около 10 видов, с сильным внутригрупповым сходством кадров (много снимков одной встречи с животным), из-за чего обучение только на нём даёт модели слабую обобщающую способность. Аналогов уровня Snapshot Serengeti или iWildCam для СНГ не существует, а собрать и разметить собственный датасет сопоставимого масштаба (как в проекте по фауне Карелии, ~6700 фото) без ресурсов на съёмку и разметку невозможно.

Гипотеза

Расширить обучающую выборку за счёт смежного домена — iNaturalist, где представлено много фотографий видов из RedForest, — и адаптировать домен. Ожидается, что модель, обученная на объединении доменов, будет классифицировать RedForest лучше, чем модель, обученная только на одном из доменов. Сложность: в iNaturalist много фото сделано людьми (не камерами-ловушками), а также встречаются следы жизнедеятельности животных, а не сами животные — нужна предобработка.

Метрика успеха

Weighted avg F1-score — учитывает precision/recall по каждому классу и корректно отражает качество в условиях дисбаланса (от тысяч фото на класс до нескольких десятков). Веса соответствуют распределению видов в тестовой выборке, что соответствует реальности камер-ловушек: редкие виды дают меньше кадров.

Данные и методология

RedForest — целевой домен, ~4 тыс. фото, ~10 видов, сильный дисбаланс. iNaturalist — источник обогащения, расширенный список из 18 видов фауны России и близлежащих регионов, включая редких (соболь, рысь). Популярные классы обрезались до 2000 примеров, хвостовые сохранялись целиком при наличии от 100 примеров, иначе класс отбрасывался.

- Фильтрация: предобученный детектор MegaDetector v5 определял присутствие и bbox животного в кадре. Записи без животного, с низкой уверенностью или подозрительно малой областью бокса выделялись в служебный класс `net_v_klassifikatore`.
- Кроп: изображения обрезались по bbox с отступом и приведением к квадрату, что позволило убрать фон, сохранило пропорции тела и снизило путаницу между морфологически схожими видами (например, рогатыми).
- Разбиение выборки: стратифицировано по виду; для iNaturalist — на уровне уникальных наблюдений (`observation_uid`), чтобы избежать утечки почти идентичных кадров между `train` и `test`.
- Модель: предобученная DINOv2 (Meta AI) + две головы — классификационная (18 классов) и эмбединг-голова (для будущих задач сравнения/идентификации особей). Для борьбы с дисбалансом использовались взвешенный сэмплер и взвешенная функция потерь.

Эксперимент

Проведены четыре итерации обучения:

1. Обучение и валидация только на RedForest (базовая точка отсчёта).
2. Обучение только на iNaturalist, валидация на RedForest.
3. Дообучение модели с iNaturalist-весами только на RedForest.
4. Дообучение на смеси iNaturalist + RedForest (replay-стратегия против catastrophic forgetting).

Результаты валидации представлены на рис. 1.




Рисунок 1 – Результаты валидаций моделей на обоих доменах

- Baseline подтверждает доменный разрыв: высокое качество на iNaturalist (0.930), но падение на 20 пунктов на RedForest (0.727).
- Обучение только на RedForest ограничено малым объёмом данных: 0.832 — лучше baseline, но ниже потенциала.
- Дообучение только на RedForest даёт максимальную адаптацию к целевому домену (0.898, +17 пунктов к baseline), но умеренно снижает качество на iNaturalist (0.904, −2.6 пункта) — эффект catastrophic forgetting есть, но не критичен.
- Replay-дообучение (совместно iNaturalist + RedForest) — самый сбалансированный результат: качество на iNaturalist полностью сохранено (0.931), качество на RedForest существенно выросло (0.871, +14.4 пунктов к baseline).

Вывод

Гипотеза подтверждена: модели, обученные только на iNaturalist, значительно теряют в качестве при переносе на снимки камер-ловушек. Этот разрыв эффективно сокращается даже при небольшом объёме целевых данных RedForest. Replay-дообучение (совместное использование исходного и

целевого доменов) показало оптимальный баланс между адаптацией к новому домену и сохранением ранее выученных знаний — это делает подход предпочтительным для практических задач классификации фауны по снимкам камер-ловушек в условиях ограниченной доступности размеченных данных целевого региона.

PS. более подробное описание проделанной работы представлено в README.md проекта.